

Calibration du vote majoritaire du garde-fou de transmission

Note méthodologique pour les rédacteurs de l'article

Projet AgriSense

1 Objet de la note

Cette note décrit comment les seuils du garde-fou ont été calibrés, quels résultats ont été obtenus et quels seuils sont retenus. Le mécanisme n'est pas modifié : une image est transmise si **au moins deux critères sur trois** dépassent leur seuil (vote majoritaire). Seule la valeur des seuils est optimisée.

2 Le mécanisme

Pour chaque paire (image précédente, nouvelle image), trois critères sont calculés.

- **HIST** : distance de Bhattacharyya entre les histogrammes couleur globaux (4 classes par canal RGB).
- **MEAN** : écart moyen, sur les trois canaux, entre les médianes des deux images.
- **PROP** : pourcentage de blocs de 32×32 pixels dont la distance de Bhattacharyya dépasse un *seuil de bloc*. Une image 640×480 contient 300 blocs.

Chaque critère vote « transmettre » lorsqu'il est **strictement supérieur** à son seuil. PROP comporte donc deux paramètres : le seuil de bloc (décision pour chaque bloc) et le seuil PROP (décision pour l'image entière). Au total, quatre valeurs sont calibrées : HIST, MEAN, PROP et le seuil de bloc.

3 Données

Le jeu de calibration contient 2 503 paires d'images étiquetées :

Étiquette	Paires	Signification
0	840	auto-paires (image comparée à elle-même), métriques nulles
1	831	images similaires (ne pas transmettre)
2	832	images différentes (transmettre)

La classe positive est l'étiquette 2. Deux scénarios sont rapportés :

- **hard** (scénario principal) : étiquettes 1 et 2 uniquement, $n = 1\,663$. Les auto-paires sont exclues car leurs métriques valent 0 et rendent le problème trivial.
- **all** : toutes les étiquettes, $n = 2\,503$. Il est optimiste et n'est donné qu'à titre indicatif.

Le jeu est équilibré par construction : il ne reflète pas la fréquence réelle des changements sur le terrain. Aucune estimation de cette fréquence n'a été faite.

4 Méthode de calibration

4.1 Recherche des seuils

Pour chaque critère, une grille de 25 valeurs est construite à partir des percentiles 2 à 98 des données d'entraînement. Toutes les combinaisons (HIST, MEAN, PROP) sont évaluées pour

chacun des cinq seuils de bloc candidats (0,05 ; 0,1 ; 0,2 ; 0,3 ; 0,5). Le point retenu est le centre du plateau quasi-optimal (tolérance 0,002), plutôt que le premier maximum, afin de favoriser la stabilité.

4.2 Objectifs opérationnels

- **bacc** : maximiser l’exactitude équilibrée, moyenne du recall (vrais changements détectés) et de la spécificité (images sans changement écartées).
- **spec@0.95** et **spec@0.98** : maximiser la spécificité sous une contrainte de recall d’au moins 0,95 ou 0,98.

4.3 Deux méthodes de calibration comparées

Classique. Le meilleur point de grille est choisi sur tout l’entraînement. Pour les objectifs **spec@**, la contrainte de recall est testée sur la borne basse de Wilson ($z = 1,645$). Le seuil de bloc est choisi par validation croisée interne (3 folds).

Robuste. Chaque point de grille est évalué sur 200 rééchantillons de 20 blocs temporels de l’entraînement. On retient le point dont la performance est atteinte dans 90 % des rééchantillons, et non seulement en moyenne. Le seuil de bloc est choisi dans la même procédure.

4.4 Validation

La performance est estimée hors échantillon par **validation croisée imbriquée** :

- cinq folds externes découpés en **blocs temporels** (ordre des numéros d’image) ;
- **purge** : toute paire d’entraînement partageant une image avec le fold de test est retirée (entre 135 et 224 paires selon le fold), car les paires forment une composante connexe et un découpage aléatoire laisserait fuir de l’information ;
- les seuils de chaque fold sont calculés sans jamais voir ses données de test.

Les intervalles de confiance à 95 % sont obtenus par bootstrap par blocs temporels (2 000 rééchantillons, 40 blocs). Les différences entre méthodes sont appariées sur les mêmes rééchantillons.

5 Résultats

5.1 Pouvoir discriminant des critères (scénario *hard*)

Critère	AUC [IC 95 %]
HIST	0,958 [0,947 ; 0,970]
MEAN	0,876 [0,856 ; 0,897]
PROP (bloc 0,05)	0,987 [0,981 ; 0,992]
PROP (bloc 0,1)	0,987 [0,980 ; 0,992]

PROP est le critère le plus discriminant, MEAN le moins.

5.2 Performances hors échantillon (scénario *hard*)

Objectif	Méthode	Recall	Spécificité	Bal. acc.	Recall du pire fold
bacc	classique	0,944	0,961	0,953	0,871
bacc	robuste	0,944	0,954	0,949	0,806
spec@0.95	classique	0,939	0,929	0,934	0,742
spec@0.95	robuste	0,936	0,948	0,942	0,742
spec@0.98	classique	0,987	0,798	0,892	0,944
spec@0.98	robuste	0,982	0,845	0,913	0,935

Intervalles de confiance à 95 % pour **bacc** classique : recall [0,917; 0,966], spécificité [0,940; 0,980].

Principales observations :

- En **bacc**, la méthode robuste ne fait pas mieux que la classique (différences non significatives) et son pire fold est moins bon.
- Aux objectifs **spec@**, la méthode robuste gagne en spécificité à recall comparable : +0,019 [+0,003; +0,042] pour **spec@0.95** et +0,047 [+0,028; +0,068] pour **spec@0.98** (intervalles excluant 0).
- La cible de recall de 0,95 n'est tenue en moyenne par aucune méthode (0,936 à 0,939), et seuls 3 folds sur 5 l'atteignent. Ce réglage ne doit pas être présenté comme garantissant 95 %.

5.3 Erreurs réelles du réglage retenu

Décisions hors échantillon de la méthode classique, objectif **bacc**, scénario *hard* :

	Bloquées (0)	Envoyées (1)
Paires similaires (831)	799 (96,1 %)	32 (3,9 %)
Paires différentes (832)	47 (5,6 %)	785 (94,3 %)

Les 32 paires similaires envoyées sont des transmissions inutiles. Les 47 paires différentes bloquées sont des changements non transmis, l'erreur la plus grave pour l'application. Avec la méthode robuste, on obtient 38 et 47.

6 Seuils retenus

Le réglage retenu est celui de l'objectif **bacc**, calibré par la méthode classique sur l'ensemble du scénario *hard* :

Paramètre	Valeur
Seuil HIST	> 0,00275
Seuil MEAN	> 16,67
Seuil PROP	> 64 % des blocs
Seuil de bloc (dans PROP)	0,05
Règle de décision	au moins 2 critères sur 3

Avec 300 blocs, un seuil de 64 % signifie plus de 192 blocs, soit au moins 193 blocs « changés ».

Justification. Ce réglage a le meilleur compromis global hors échantillon en **bacc**, et le pire fold le moins mauvais. Le seuil de bloc 0,05 est sélectionné dans les 5 folds, et le seuil PROP varie peu (55,5 à 69,9 % selon les folds). L'objectif **bacc** traite de façon symétrique les transmissions inutiles et les changements non transmis.

Alternative prudente. Pour ne presque rien rater, l'objectif **spec@0.98** détecte environ 98,7 % des vrais changements (classique) au prix de 20 % de transmissions inutiles en plus. Les seuils de la méthode robuste étant instables pour cet objectif (intervalles de confiance très larges sur HIST et MEAN), ce réglage doit être présenté avec réserve.

7 Limites à mentionner dans l'article

- **Les gains ne sont pas mesurés en énergie.** Aucune mesure énergétique n'a été faite : l'article doit exprimer les bénéfices en *transmissions inutiles évitées* (environ 96 % des paires similaires bloquées), non en énergie.

- **Fréquence réelle des changements inconnue.** Le jeu est équilibré : le taux global de transmissions évitées sur le terrain n'est pas estimable avec ces données.
- **Variabilité entre périodes.** Le pire fold rate 12,9 % des vrais changements (recall 0,871), contre 5,6 % en moyenne.
- **Rôle limité de MEAN.** Dans le réglage retenu, MEAN n'est décisif que dans environ 12 % des paires : le vote se joue surtout entre HIST et PROP.
- **Scénario *all*.** Il inclut les auto-paires triviales et surestime les performances ; il ne doit pas être utilisé comme résultat principal.
- **Comparaison avec l'existant non réalisée.** L'amélioration par rapport aux seuils actuels de l'article n'a pas encore été mesurée (voir ci-dessous).

8 À faire avant soumission

1. Relancer la calibration avec `-article-thresholds HIST,MEAN,PROP -article-block B` pour chiffrer le gain par rapport aux seuils actuels, avec un intervalle de confiance.
2. Vérifier que le firmware reproduit exactement les métriques du script : résolution 640×480 , blocs 32×32 , histogrammes à 4 classes par canal, distance de Bhattacharyya, comparaison stricte $>$.
3. Idéalement, valider le réglage retenu sur un jeu collecté séparément (autre période ou autre site).